

Finance Agent

可审计的多源股票研究智能体

基于工具调用、多源证据与多智能体辩论的金融研究助手

模型负责理解与编排 × 程序负责数据、计算与约束

李宇航 童泽远 马玉玺

人工智能前沿实践·课程项目

问题：为什么不能直接问大模型“这只股票能买吗”？

01 数据会过时

行情、财报和新闻持续变化，模型参数中的知识不能代替实时查询。

后果：引用旧价格或旧事件

02 事实难核验

单一来源可能缺失或冲突；模型还可能补出看似合理但无依据的数字。

后果：结论与证据脱节

03 观点容易单一

同一模型常沿着最先形成的叙事继续推理，并给出过度确定的判断。

后果：风险和反例被忽略

我们要解决的不是“让模型记住更多金融知识”，而是让它查到、核对、引用并限制结论。

相关工作：已有方法各解决了一部分问题

金融问答 / RAG

从财报或金融语料中检索并回答问题。

- + 比纯参数记忆更可查
- 实时行情和跨源冲突仍需处理

代表：FinQA、FinGPT

工具调用 Agent

模型在推理过程中选择搜索、计算或外部 API。

- + 能获取任务所需的新信息
- 工具结果不等于可靠证据

代表：ReAct、Tool Calling

多智能体分析

不同角色分别分析，再讨论或交给 Judge 汇总。

- + 主动暴露分歧和反例
- 角色变多不保证事实正确

代表：AutoGen、Debate

本项目关注三者交叉处：真实工具 + 统一证据 + 多视角裁决 + 代码级质量约束。

挑战与创新：只解决三个真正影响结论的问题

多源缺失与不一致

挑战 行情、历史和财务数据覆盖不同。

做法 ProviderChain 并发查询，按时效和完整度选择/融合，并保留 coverage 与 conflict。

工具调用

并行执行

单模型偏见与过度自信

挑战 同一模型容易忽略反例。

做法 五个角色独立分析；Bull/Bear 交叉反驳；Judge 只基于同一证据集裁决。

多智能体协作

LLM-as-Judge

结论缺少证据与边界

挑战 有工具仍可能“引用错数字”。


做法 编号证据、数字校验、QualityGate 评级；字段不足时删除说法并限制把握上限。

上下文契约

安全机制

方法：从用户问题到可审计研究报告

ReAct / Tool Calling



同一份证据

独立分析后再辩论

程序限制无依据输出

实现依据: agent/loop.py · finance/data.py · finance/debate_orchestrator.py · finance/quality.py

实验：AAPL 真实运行，系统如何限制一个“看似完整”的结论？

真实数据摘要

2026-07-14

行情 317.31 USD, 当日 +0.63% (Yahoo)
 历史 251 点; MA20 299.19, MA60 293.91
 动量 RSI14 64.16; 近 3 月 +21.82%
 风险 年化波动率 24.12%
 财务 EPS 7.49; 营收 416.16B (AKShare)
 缺口 PE、自由现金流缺失
 新闻 5 条 Yahoo 公司相关新闻

QualityGate: B

多类数据实际仍为单源覆盖

Bull 盈利与动量较强；但高杠杆和缺失字
段削弱正面判断。

Bear 杠杆、PE/自由现金流缺失和近期涨
幅带来下行风险。

Judge + 代码校验

评分 4.0/10; 30 天方向 down; 引用 Q1、F8、G1、N1。

模型给出 55% 把握，因来源覆盖和校验问题，代码限制为
40% 上限。

未被证据支持的数字被删除；含无依据数字的结论改为“需人
工复核”。

相比单模型直接回答：数据缺口被显式暴露，分歧被保留，无依据数字被程序拦截。

思考：多一个 Agent，不等于多一份真相

1. **多智能体是否更准确？** 角色增加了反例，但也增加成本和共同错误的机会。
2. **Judge 是否真正独立？** 它仍可能受前序角色的表达顺序和框架影响。
3. **数据是否足够新、足够全？** AAPL 案例已暴露单源覆盖与关键字段缺失。
4. **回测是否能代表未来？** 只能检验历史流程，不能保证未来收益。

边界

研究辅助，不是交易系统

不执行真实交易
不把回测当收益承诺
信息不足时允许“不下结论”

安全机制

可观测性

总结：把“会回答”变成“可检查的研究过程”

01

解决的问题

过时数据、单源冲突、单模型偏见和无依据数字。

02

核心方法

ReAct 工具调用 + Provider-Chain + 统一证据 + 多智能体与 Judge + Quality-Gate。

03

实际效果

AAPL 实测中暴露数据缺口、删除无依据数字，并把 55% 模型信号限制到 40% 上限。

模型负责理解与编排，确定性程序负责数据、计算和安全。